

Chiến lược phát hiện Deepfake đa phương thức dựa trên sự bất nhất quán ngữ âm và hình thái học cho hệ sinh thái ngôn ngữ Việt Nam

Nguyễn Minh Nhật, Nguyễn Lâm Anh, Nguyễn Văn Linh

Mục lục

1	Lời mở đầu	2
2	Ba thách thức cốt lõi	2
3	Tại sao các mô hình quốc tế thất bại?	2
4	Phương pháp đề xuất: Kiến trúc PAMF	3
4.1	Kiến trúc tổng thể	3
4.2	Cơ chế hoạt động	3
4.3	Công thức toán học	4
5	Chiến lược xây dựng và huấn luyện dữ liệu VN-AV-DF	4
5.1	Nguồn dữ liệu thật	4
5.2	Pseudo-fake Engineering	4
5.3	Mô phỏng môi trường nén	4
5.4	Quy mô dự kiến	4
5.5	Social Network Video Sharing Simulator (SNVSM) trong Training	5
6	Giao thức đánh giá	5
6.1	Các chỉ số đánh giá chuyên biệt	6
6.2	Các câu hỏi nghiên cứu (RQs)	6
7	Nâng cao độ bền vững và phòng thủ đối kháng	6
8	Kết luận và hướng phát triển	6
	Rủi ro và phương án dự phòng	7

1 Lời mở đầu

Thưa thầy/cô,

Nhóm em xin trình bày đề cương nghiên cứu về phát hiện deepfake đa phương thức, tập trung vào khai thác đặc thù ngữ âm tiếng Việt. Vấn đề deepfake đang trở thành công cụ lừa đảo chính tại Việt Nam, gây thiệt hại ước tính hơn 6.000 tỷ đồng trong năm 2025 – chiếm 75% tổng thiệt hại từ lừa đảo trực tuyến (khoảng 8.000 tỷ đồng). Các mô hình phát hiện quốc tế (SyncNet, Lip Forensics, AV-HUBERT) thất bại trước đặc thù ngôn ngữ có dấu và môi trường nén video mạnh của Zalo, Telegram.

Nhóm đề xuất hệ thống **PAMF (Phonetic-Aware Multimodal Fusion)** – phát hiện dựa trên sự bất nhất quán giữa âm thanh và hình ảnh (AV-Sync). Điểm mới là tận dụng các thanh điệu độc đáo của tiếng Việt (thanh Hô giọng thờ, thanh Ngã giọng gây) cùng chuyển động cơ cổ/môi để phát hiện deepfake kể cả khi video bị nén mạnh.

Sản phẩm dự kiến:

- Bộ dataset **VN-AV-DF** đầu tiên cho tiếng Việt (khoảng 12.000 video, đa dạng phương ngữ Bắc – Trung – Nam, bao gồm cả video nén CRF 35+ mô phỏng Zalo/Telegram).
- Mô hình **PAMF** và code nguồn mở trên GitHub.
- Kết quả đánh giá so sánh với các baseline quốc tế (Xception, MesoNet, EfficientNet-B4).
- Báo cáo phân tích chi tiết và hướng dẫn tái tạo.

Dự án dự kiến hoàn thành trong 6 tháng với lộ trình rõ ràng và các phương án dự phòng cho rủi ro kỹ thuật.

2 Ba thách thức cốt lõi

- **Deepfake là công cụ lừa đảo chính tại Việt Nam:** Năm 2025, lừa đảo trực tuyến gây thiệt hại hơn 8.000 tỷ đồng. Dự báo năm 2026, tội phạm mạng sẽ dùng deepfake tạo ra hình ảnh, video, giọng nói cực kỳ chân thực để lừa đảo. Bộ Công an đã đề xuất xử lý hình sự hành vi phát tán deepfake và thao túng dữ liệu.
- **Khoảng cách tổng quát hóa (Generalization Gap):** Các mô hình đạt hiệu suất cao trên FF++, DFDC nhưng thất bại tại Việt Nam. Nguyên nhân: (a) Không nhận diện được đặc thù ngôn ngữ có dấu và nhân chủng học Đông Nam Á; (b) Thuật toán nén H.264 CRF 35+ trên Zalo, Telegram làm phẳng kết cấu nhiễu pixel (forensic laundering), vốn là căn cứ chính của các detector dựa trên artifact GAN.
- **Thiếu benchmark cho tiếng Việt:** Các bộ dữ liệu hiện có (FF++, Celeb-DF, DFDC, FakeAVCeleb, SEA-Spoof) đều có điểm yếu. FakeAVCeleb mắc lỗi “silence shortcut” (đoạn im lặng đầu video giúp model đoán fake mà không cần học lệch pha). Không có bộ dữ liệu nào mô phỏng môi trường nén thực tế của Zalo/Telegram hoặc bao gồm đầy đủ biến thể phương ngữ.

Nhóm em cho rằng cần chuyển hướng sang phương pháp phát hiện dựa trên đồng bộ âm thanh – hình ảnh (AV-Sync), chuyên biệt cho tiếng Việt, kết hợp xây dựng dữ liệu mô phỏng nén thực tế.

3 Tại sao các mô hình quốc tế thất bại?

Bảng dưới đây tóm tắt điểm yếu của các mô hình tiền nhiệm khi áp dụng cho tiếng Việt.

Kết luận: Các mô hình quốc tế thất bại vì ba lý do chính: (1) Không khai thác đặc thù ngữ âm của ngôn ngữ có dấu; (2) Phụ thuộc vào pixel artifacts dễ bị phá hủy bởi nén; (3) Quá nặng hoặc không tối ưu cho môi trường thực tế tại Việt Nam.


Bảng 1: So sánh các mô hình phát hiện deepfake tiền nhiệm

Mô hình	Công nghệ cốt lõi	Điểm yếu với tiếng Việt / nén video
SyncNet	Two-stream ConvNet + MFCC	Đánh giá đồng bộ thô, không đủ nhạy với biến đổi cao độ (F0) của thanh Hô/Ngã.
Lip Forensics	Spatio-temporal network	Khó nhận diện đồng bộ khi phát âm các thanh điệu đặc thù.
AV-HUBERT (Meta)	Self-supervised learning, 100M+ tham số	Quá nặng, khó real-time; dễ sụt giảm hiệu năng khi nén mạnh (CRF 35+).
Xception / MesoNet	CNN-based visual artifact	Phụ thuộc hoàn toàn vào pixel artifacts, bị vô hiệu hóa bởi nén video.

4 Phương pháp đề xuất: Kiến trúc PAMF

PAMF tập trung vào **sự bất nhất quán giữa âm thanh và chuyển động hình ảnh (AV-Sync)**, đặc biệt khai thác các **dấu vết pháp y vật lý** từ thanh điệu tiếng Việt.

4.1 Kiến trúc tổng thể



Hình 1: Sơ đồ kiến trúc PAMF

4.2 Cơ chế hoạt động

- **Nhánh âm thanh:** Dùng mô hình SSL (Wav2Vec2 hoặc WavLM) để trích xuất đặc trưng âm học, tập trung vào quỹ đạo cao độ (F0), Jitter, Shimmer – những chỉ số quan trọng để nhận dạng hiện tượng âm hầu hóa (glottalization) của thanh Ngã. Chọn Wav2Vec2/WavLM thay vì AV-HUBERT vì chúng nhẹ hơn, phù hợp cho real-time.

- **Nhánh hình ảnh:** Sử dụng YOLOv8-Face để crop vùng môi – cằm (Region of Interest). Kỹ thuật *Dynamic Keyframe Sampling* chỉ lấy mẫu tại các mốc thời gian đạt đỉnh năng lượng (formants), giảm 60% chi phí tính toán.
- **Fusion bằng Cross-Modal Attention:** Lấy đặc trưng âm thanh làm Query, đặc trưng hình ảnh làm Key và Value. Attention học cách gán trọng số cao vào đúng khung hình khẩu hình miệng tương ứng với âm tiết. Nếu AI tạo ra lệch pha vì mô (ví dụ: môi tròn tru trong khi âm thanh bị gãy – glottal stop), độ tương quan trong không gian Attention sẽ sụt giảm, giúp phát hiện deepfake.

4.3 Công thức toán học

Thuật toán Dynamic Time Warping (DTW) bù đắp biến động tốc độ nói phi tuyến tính. Gọi V là chuỗi đặc trưng hình ảnh, A là chuỗi đặc trưng âm thanh:

$$D(V, A) = \min_W \sum_{k=1}^K d(v_{i_k}, a_{j_k}) \quad (1)$$

Độ tương đồng Cosine tại thời điểm t :

$$S_c(v_t, a_t) = \frac{v_t \cdot a_t}{\|v_t\| \|a_t\|} \quad (2)$$

Chỉ số tin cậy cuối cùng:

$$C = \frac{1}{1 + e^{-S_c}} \quad (3)$$

5 Chiến lược xây dựng và huấn luyện dữ liệu VN-AV-DF

5.1 Nguồn dữ liệu thật

Khai thác Vietnam-Celeb, SEA-Spoof, kết hợp video thời sự, podcast, vlog để đa dạng bối cảnh và góc quay. Thu thập đủ ba phương ngữ **Bắc – Trung – Nam** (tỷ lệ 40% : 30% : 30%) để mô hình không bị đánh lừa bởi khác biệt viseme giữa các vùng.

5.2 Pseudo-fake Engineering

Chúng tôi chủ động tạo ra các mẫu giả với lỗi vật lý mục tiêu, giúp mô hình học đúng bản chất vật lý thay vì học vẹt.

5.3 Mô phỏng môi trường nén

Toàn bộ video giả được xử lý qua module **SNVSM** (Social Network Video Sharing Simulator): nén H.264 với CRF từ 23 đến 40 (CRF 35+ tương đương Zalo/Telegram).

5.4 Quy mô dữ kiện

- Tập train: 5.000 video thật + 5.000 video pseudo-fake (đa dạng phương ngữ)
- Tập validation: 1.000 video (500 thật, 500 fake)
- Tập test: 1.000 video (500 thật, 500 fake), gồm test sạch và test nén CRF 35+, 40+

Bảng 2: Các kỹ thuật pseudo-fake cho tiếng Việt

Kỹ thuật	Cách thực hiện	Mục tiêu
Temporal Desync	Dịch âm thanh lệch 3–15 frames so với visual.	Học căn chỉnh thời gian nhạy bén.
Prosody Manipulation	Làm phẳng cao độ (pitch flattening) của thanh Hỏi/Ngã.	Phát hiện vận luật (prosody) không tự nhiên.
Glottalization Inconsistency	Giữ môi tròn tru trong khi âm thanh có glottal stop.	Bắt lỗi vật lý cốt lõi: thanh Ngã bị gãy nhưng môi/cổ không phản ứng.
Local Temporal Inconsistencies	Chèn môi của người khác hoặc đảo ngược frame.	Buộc mô hình dựa vào logic chuyển động, không phải artifact GAN.

Bộ dữ liệu sẽ được công khai trên GitHub (tuân thủ điều kiện đạo đức).

5.5 Social Network Video Sharing Simulator (SNVSM) trong Training

Để mô hình có thể hoạt động tốt trong môi trường thực tế (Zalo, Telegram), nhóm em tích hợp trực tiếp module **SNVSM** vào quá trình huấn luyện như một kỹ thuật *data augmentation động*. Cụ thể:

- Sử dụng thư viện **ffmpeg-python** nhúng ngay trong **Dataloader** của PyTorch.
- Mỗi khi load một batch video, module SNVSM sẽ nén video về chuẩn H.264 với tham số lượng tử hóa (Quantization Parameter – QP) được chọn **ngẫu nhiên** trong khoảng từ 23 đến 40 (QP càng cao, video càng mờ và bị nén mạnh, tương đương CRF 35+ trên Zalo).
- Quá trình nén diễn ra *on-the-fly*, không lưu trữ trước, đảm bảo tính đa dạng của dữ liệu qua mỗi epoch.

Tác dụng chính:

- Làm phẳng (flattening) mọi nhiễu nhỏ li ti do GAN hoặc Diffusion tạo ra ở mức pixel – vốn là dấu vết mà các detector quốc tế thường dựa vào.
- Buộc mô hình PAMF **không được phép phụ thuộc vào lỗi thị giác vi mô**, thay vào đó phải học các quy luật vật lý bất biến ở mức cao hơn (sự đồng bộ âm thanh – khẩu hình, đặc trưng prosody, chuyển động cơ cổ...).
- Nhờ đó, PAMF có thể “*nhìn xuyên qua*” lớp nén mờ, vẫn phát hiện chính xác deepfake kể cả sau khi video được đăng tải qua các nền tảng xã hội.

Kỹ thuật này kết hợp với pseudo-fake engineering tạo ra một đường ống huấn luyện mạnh mẽ, hướng đến khả năng tổng quát hóa cao trong điều kiện thực tế.

6 Giao thức đánh giá

Chúng tôi đề xuất 3 giao thức đánh giá trọng tâm:

1. **Giao thức 1 – Phát hiện cơ bản & tổng quát hóa:** Đánh giá trên tập test sạch (Accuracy, Precision, Recall, AUC-ROC, F1). Kiểm tra trên các dạng fake chưa thấy (Wav2Lip, SadTalker) và phân tích theo vùng miền, giới tính. Thử nghiệm với audio nén MP3 32kbps mô phỏng voice note.
2. **Giao thức 2 – Độ bền vững với nén video:** Nén video với CRF 23, 30, 35, 40. Tính Accuracy Drop Rate (ADR) và Compression Robustness Score (CRS). So sánh hiệu suất giữa video sạch và video nén.
3. **Giao thức 3 – So sánh cross-benchmark:** So sánh PAMF với Xception, MesoNet, EfficientNet-B4 trên tập test tiếng Việt. Đo lường performance gap và thời gian inference (ms/video) trên GPU NVIDIA T4.

6.1 Các chỉ số đánh giá chuyên biệt

- **CMCS (Cross-Modal Consistency Score)**: Dựa trên trọng số Attention, thấp khi có lệch pha mạnh.
- **LSER (Lip-Sync Error Rate)**: Tỷ lệ video bị phát hiện sai do lỗi đồng bộ môi – âm thanh.
- **EER (Equal Error Rate)**: $FAR = FRR$.
- **ADR (Accuracy Drop Rate) & CRS (Compression Robustness Score)**.
- **Inference Time per Video**: Hướng tới 60 FPS.

6.2 Các câu hỏi nghiên cứu (RQs)

- **RQ1**: PAMF có phát hiện deepfake tiếng Việt tốt hơn các baseline quốc tế không? (Kỳ vọng: $AUC > 0.95$ trên test sạch, > 0.85 trên test nén CRF 35+)
- **RQ2**: Mức độ nén (CRF 23–40) ảnh hưởng đến hiệu suất của PAMF ra sao so với baseline? (Kỳ vọng: ADR của PAMF $< 10\%$, baseline $> 30\%$)
- **RQ3**: Có performance gap đáng kể giữa mô hình quốc tế và mô hình chuyên biệt cho tiếng Việt không? (Kỳ vọng: Gap $> 20\%$ AUC)

7 Nâng cao độ bền vững và phòng thủ đối kháng

- **Adversarial Training (AT)**: Đưa mẫu đối kháng (FGSM, PGD, FPBA) vào huấn luyện.
- **Frequency-Selective AT (F-SAT)**: Bảo vệ thành phần cao tần của âm thanh và hình ảnh, cải thiện 29.3% độ chính xác trên mẫu bị tấn công.
- **Input Preprocessing (Feature Squeezing)**: Lọc nhiễu đối kháng biên độ thấp trước khi đưa vào detector.
- **Robustness với phương ngữ và điều kiện thực tế**: Tập dữ liệu VN-AV-DF bao phủ Bắc–Trung–Nam; augmentation âm thanh (thay đổi tốc độ, nhiễu nền SNR 10–30 dB) và hình ảnh (sáng/tương phản, dropout khung hình) giúp mô hình chịu được biến động đầu vào.
- **Kiến trúc R2BD cho video call 60 FPS**: Sử dụng Flow Matching tái cấu trúc khuôn mặt – sai khác giữa ảnh gốc và ảnh tái tạo phát hiện deepfake từ GAN, Diffusion, Flow Matching với độ trễ thấp.

8 Kết luận và hướng phát triển

PAMF và bộ dữ liệu VN-AV-DF giải quyết ba thách thức: (1) Deepfake lừa đảo tại Việt Nam gây thiệt hại lớn; (2) Mô hình quốc tế thất bại vì generalization gap và nén video; (3) Thiếu benchmark tiếng Việt. Bằng cách khai thác đặc thù ngữ âm (thanh Hỏi/Ngã, glottalization, phương ngữ) và sự bất nhất quán AV-Sync, hệ thống của nhóm em vượt qua giới hạn của phương pháp dựa trên pixel artifacts, đặc biệt bền vững trong môi trường nén CRF 35+ (Zalo/Telegram).

Cuối năm 2026, hướng phát triển tiếp theo là kết hợp phát hiện lỗi vật lý với hạ tầng xác thực nguồn gốc nội dung (C2PA – Content Provenance and Authenticity), tạo ra hàng rào bảo vệ toàn diện cho người dùng Việt Nam. Kết quả của dự án – dataset, model, benchmark, báo cáo – sẽ được công bố mã nguồn mở, đóng góp tích cực vào an ninh không gian số quốc gia và phòng chống tội phạm công nghệ cao.

Rủi ro và phương án dự phòng

- **R1 – Thiếu dữ liệu thật:** Mở rộng khai thác YouTube, TikTok có kiểm duyệt thủ công.
- **R2 – Pseudo-fake không đủ thực:** Cập nhật kỹ thuật mới (FreqBlender, CPL).
- **R3 – Mô hình không đạt real-time:** Giảm số keyframe, dùng knowledge distillation, thử MobileNet.
- **R4 – Thiếu GPU mạnh:** Dùng Google Colab Pro (T4), tối ưu batch size, mixed precision.
- **R5 – Overfit:** Đánh giá trên tập test ngoài, tăng cường augmentation, dropout.